

昇腾长文本推理优化总体架构

围绕 PD 分离隔离阶段干扰，并用 PCP/DCP 与动态 CP 缓解长上下文带来的计算、显存和 HBM 访存瓶颈

Profiling: HBM 读写、AI Core 利用率、KV 传输时间

Prefill 资源池

计算密集：长 prompt 编码、KV 生成、TTFT

P0 P1 P2 P3

PCP
序列切分

高 TP/PP
批量计算

目标：降低 TTFT，充分利用 AI Core

KV Connector

rank/layer 映射

KV 传输

layout 转换

PageAttention 写入

Decode 资源池

访存密集：KV 读取、逐 token 生成、TPOT/ITL

D0 D1 D2 D3

DCP
KV 分片

动态 CP
跨 DP 协同

目标：降低 HBM 压力与尾部 ITL

长上下文
请求流

入口调度
P/D 路由

输出
token 流

长上下文输入

→ Prefill 计算放大

→ KV 传输/重排

→ Decode HBM 访存

→ TTFT/TPOT/ITL 优化