

DyCP 架构与运行时决策

P 侧按 prompt 长度动态选择 CP size 并生成分片 KV，D 侧根据上下文长度、KV usage 与负载选择 CP size 并跨 DP 聚合 attention

