

Decode 节点动态 CP 与跨 DP 调度

短请求保持 CP=1 的低开销路径，超长请求按需跨多个 DP-attention 副本协同处理，缓解 Decode 阶段 KV 访存 straggler

