


PD 分离中的 KV Cache 布局映射与转换

P/D 两侧 TP、PP 与注意力结构可能不同，Connector 需要把源端 KV 精确转换成 Decode 侧 PageAttention 可消费的 block 布局



MLA: 可在等价 P rank 集合内任意消费
GQA/MHA/MQA: 必须按 KV head 和 layer 精确匹配, 避免 head 缺失或 block 无法消费