

PD 分离中的 KV Cache 布局映射与转换

源端按 TP/PP 与 KV head 生成缓存，连接器按映射关系传输和重排，目标端按 PageAttention 槽位消费分片 KV

1 Prefill 侧 KV 生成

P: TP=4, PP=2

PP	P rank	KV head	block sequence
stage 0	P0	h0	B0 B1 ... Bn
stage 0	P1	h1	B0 B1 ... Bn
stage 1	P2	h2	B0 B1 ... Bn
stage 1	P3	h3	B0 B1 ... Bn

GQA / MHA / MQA: KV head 随 TP rank 切分
生成结果携带 layer、head、block 与源 rank 元数据

2 KV Connector

1 感知 TP / PP / layer partition

2 选择 P rank 或等价 rank 集合

路由元数据 + KV block

3 跨设备传输 / RDMA / 集合通信

4 按 block 执行 split / cat / transpose

连接器目标：合并重复的 block copy、reshape 与
kernel launch，输出 D 侧可直接写入的 KV block 流

目标槽位写入

3 Decode 侧 KV 消费

D: TP=2

PageAttention block table / slot mapping

D rank 0

h0 h1

B0

B1

B2

local write → decode forward

D rank 1

h2 h3

B3

B4

B5

local write → decode forward

写入完成后释放 P 侧缓存；D 侧读取分片 KV 并保持
注意力输出一致

约束与兼容性

MLA: 可在等价源 rank 中选择

MHA / GQA / MQA: KV head 与 layer 必须精确匹配

避免 head 缺失、layer 错位或 block 不可读