

## 实验输入

Qwen / DeepSeek

昇腾 910 系列

4K-1M 上下文

1-16 rps

DP / 静态 CP 基线

1 瓶颈量化  
TTFT / TPOT / ITL  
HBM 与 AI Core

2026.06-08

2 PD Connector  
TP/PP/MTP 映射  
KV layout 转换

2026.09-11

3 中心化调度  
Domain /  
KV usage  
min(KV usage)

2026.12-2027.01

4 动态 CP 调度  
Decode:  
DP/全量 CP  
Prefill: PCP 二选一

2027.02-03

统一评估

延迟: TTFT  
/ TPOT / ITL

资源: 显存 / HBM / 带宽

系统: QPS / 负载均衡

KV 传输时间、layout 转换时间、算子 launch、输出一致性

## 阶段产出

PD 传输适配

DPLB 调度原型

跨 DP 协同机制

动态 CP 收益边界

论文图表与消融