

大模型推理中缓解 MoE 气泡的全量上下文并行调度方法、装置、电子设备和计算机可读介质

摘要

本申请实施例公开了一种大模型推理中缓解混合专家模型 MoE 气泡的全量上下文并行调度方法、装置、电子设备和计算机可读介质。主要技术方案包括：接收大模型推理请求，获得请求的上下文长度、键值缓存需求量、服务等级目标以及 MoE 层路由相关统计；采集多个数据并行计算副本的运行状态，所述运行状态包括各计算副本的键值缓存使用量、待处理请求数、注意力阶段预计完成时间、MoE 层同步等待时间、专家输入负载偏斜和跨副本通信状态；根据所述运行状态估计将所述推理请求以数据并行路径执行时产生的 MoE 气泡代价，以及将所述推理请求以预设计算域内全量上下文并行路径执行时产生的 MoE 气泡代价和通信代价；在所述全量上下文并行路径能够降低数据并行副本间到达 MoE 层的时间差或专家负载偏斜的情况下，将所述推理请求绑定至所述预设计算域内的全部参与副本，将键值缓存沿序列维度分片至所述全部参与副本，并聚合各参与副本的分片注意力计算结果；否则，将所述推理请求调度至单个目标计算副本以数据并行路径执行。该方式在数据并行路径和预设全量上下文并行路径之间进行运行时选择，能够缓解数据并行副本间负载不均衡导致的 MoE 同步等待气泡，降低尾延迟并提升大模型推理吞吐。

权利要求书

1. 一种大模型推理中缓解 MoE 气泡的全量上下文并行调度方法，其特征在于，所述方法包括：接收大模型的推理请求，获得所述推理请求的上下文长度、键值缓存需求量、服务等级目标以及 MoE 层路由相关统计；

获得推理系统中多个数据并行计算副本的运行状态，所述运行状态包括各计算副本的键值缓存使用量、待处理请求数、注意力阶段预计完成时间、MoE 层同步等待时间、专家输入负载偏斜和跨副本通信状态；

根据所述运行状态估计所述推理请求在数据并行路径下的第一气泡代价，以及所述推理请求在预设计算域内全量上下文并行路径下的第二气泡代价和通信代价；

响应于所述第二气泡代价低于所述第一气泡代价且所述通信代价满足预设约束，将所述推理请求绑定至所述预设计算域内的全部参与副本，以全量上下文并行路径执行；

响应于所述第二气泡代价不低于所述第一气泡代价或所述通信代价不满足预设约束，将所述推理请求调度至一个目标计算副本，以数据并行路径执行；

其中，所述全量上下文并行路径包括：将所述推理请求的键值缓存沿序列维度分片至所述全部参与副本，维护跨副本缓存映射，由所述全部参与副本基于本地键值缓存分片执行分片注意力计算，并聚合分片注意力计算结果以生成所述推理请求的输出 token。

2. 根据权利要求 1 所述的方法，其特征在于，所述 MoE 层路由相关统计包括以下至少一种：各 MoE 层的专家命中计数、top-k 路由分布、专家容量因子、被丢弃或重路由的 token 数、专家输入 token 数的方差、最大专家输入 token 数与平均专家输入 token 数的比值。
3. 根据权利要求 1 所述的方法，其特征在于，所述第一气泡代价根据将所述推理请求分配至单个目标计算副本后，所述目标计算副本到达 MoE 同步点的预计时间与同一 MoE 同步组内其他计算副本到达 MoE 同步点的预计时间之间的差值确定。
4. 根据权利要求 1 所述的方法，其特征在于，所述第二气泡代价根据所述全量上下文并行路径下各参与副本的注意力阶段分片执行时间、分片结果聚合时间、MoE 层同步点到达时间以及专家输入负载偏斜确定。
5. 根据权利要求 1 所述的方法，其特征在于，所述预设计算域由部署配置确定，包括同一通信域内的全部数据并行计算副本、同一节点内的全部数据并行计算副本或跨节点通信带宽满足预设条件的一组数据并行计算副本；所述全量上下文并行路径使用所述预设计算域内的全部参与副本。
6. 根据权利要求 1 所述的方法，其特征在于，所述目标计算副本由中心化调度器选择，所述中心化调度器维护全局等待队列以及各计算副本的键值缓存使用量、待处理请求数和 MoE 气泡统计，并选择综合负载评分最低且剩余键值缓存容量满足所述推理请求需求的计算副本作为目标计算副本。
7. 根据权利要求 6 所述的方法，其特征在于，所述综合负载评分根据键值缓存使用量、待处理请求数、预计注意力完成时间、历史 MoE 同步等待时间和专家负载偏斜中的至少一种确定。
8. 根据权利要求 1 所述的方法，其特征在于，所述将所述推理请求的键值缓存沿序列维度分片至所述全部参与副本，包括以下至少一种：按照连续 token 区间分片、按照固定大小的键值缓存块轮转分片、按照预设交错粒度在多个参与副本间交错分片。
9. 根据权利要求 1 所述的方法，其特征在于，所述维护跨副本缓存映射，包括：维护二维槽位映射表，所述二维槽位映射表的第一维对应参与副本标识，第二维对应序列位置或缓存块编号，所述二维槽位映射表中的元素记录物理槽位编号、块状态、引用计数、所属请求标识和数据可读状态。

10. 根据权利要求 9 所述的方法，其特征在于，所述方法还包括：基于所述二维槽位映射表生成虚拟块索引，并将所述虚拟块索引提供给注意力后端，使所述注意力后端通过逻辑连续的虚拟块访问分布在所述全部参与副本上的键值缓存。

11. 根据权利要求 1 所述的方法，其特征在于，所述聚合分片注意力计算结果，包括：各参与副本分别基于本地键值缓存分片计算本地注意力输出 O_r 和本地指数归一化统计量 LSE_r ；在参与副本之间交换或归约各自的 LSE_r ，并确定 $LSE_{max} = \max_r(LSE_r)$ ；根据 $w_r = \exp(LSE_r - LSE_{max})$ 计算各参与副本的输出权重；按照 $O = (\sum_r w_r \cdot O_r) / (\sum_r w_r)$ 聚合各参与副本的本地注意力输出，得到与未分片注意力计算一致的全局注意力输出。

12. 根据权利要求 1 所述的方法，其特征在于，所述方法还包括：在全量上下文并行路径下，为所述推理请求生成路由元数据，所述路由元数据包括请求标识、预设计算域标识、全部参与副本集合、跨副本缓存映射和结果聚合路径，并将所述路由元数据注入批次执行描述符或计算图。

13. 根据权利要求 1 所述的方法，其特征在于，所述方法还包括：在所述全部参与副本完成分片注意力结果聚合后，使所述全部参与副本在同一 MoE 同步组内进入 MoE 层的专家路由、跨专家通信或专家前馈计算，以降低所述同一 MoE 同步组内的等待时间差。

14. 根据权利要求 1 所述的方法，其特征在于，所述方法还包括：根据连续多个解码步中的 MoE 同步等待时间和专家输入负载偏斜更新气泡代价估计参数，并在后续请求到达时利用更新后的气泡代价估计参数在数据并行路径和全量上下文并行路径之间进行选择，其中所述预设计算域内的参与副本集合保持不变。

15. 根据权利要求 1 所述的方法，其特征在于，所述方法还包括：在预填充阶段和解码阶段部署在不同计算设备组的情况下，根据源端并行配置、目标端并行配置以及注意力结构确定键值缓存布局映射关系，并按照所述键值缓存布局映射关系传输和转换键值缓存。

16. 根据权利要求 15 所述的方法，其特征在于，所述键值缓存布局映射关系包括键值头编号、层编号、源端张量并行标识、目标端张量并行标识、源端流水并行阶段和目标端流水并行阶段之间的映射关系；所述注意力结构包括多头注意力、分组查询注意力、多查询注意力或多头潜在注意力中的至少一种。

17. 一种大模型推理中缓解 MoE 气泡的全量上下文并行调度装置，其特征在于，所述装置包括：请求分析模块，被配置为接收大模型的推理请求，获得所述推理请求的上下文长度、键值缓存需求量、服务等级目标以及 MoE 层路由相关统计；

状态采集模块，被配置为获得推理系统中多个数据并行计算副本的键值缓存使用量、待处理请求数、注意力阶段预计完成时间、MoE 层同步等待时间、专家输入负载偏斜和跨副本通信状态；

气泡代价估计模块，被配置为估计所述推理请求在数据并行路径下的第一气泡代价，以及在预设计算域内全量上下文并行路径下的第二气泡代价和通信代价；

路径选择模块，被配置为在所述第二气泡代价低于所述第一气泡代价且所述通信代价满足预设约束时选择全量上下文并行路径，否则选择数据并行路径；

缓存分片管理模块，被配置为在全量上下文并行路径下将键值缓存沿序列维度分片至全部参与副本，并维护跨副本缓存映射和虚拟块索引；

注意力执行模块，被配置为执行分片注意力计算并聚合分片注意力计算结果；

MoE 对齐模块，被配置为根据注意力阶段完成时间和 MoE 层同步等待时间调度所述推理请求进入 MoE 层。

18. 一种电子设备，其特征在于，包括：一个或多个处理器；与所述一个或多个处理器关联的存储器，所述存储器用于存储程序指令，所述程序指令在被所述一个或多个处理器读取执行时，执行权利要求 1 至 16 中任一项所述的方法的步骤。

19. 一种计算机可读介质，其上存储有计算机程序，其特征在于，该程序被处理器执行时实现如权利要求 1 至 16 中任一项所述的方法的步骤。

20. 一种计算机程序产品，包括计算机程序，其特征在于，该计算机程序被处理器执行时实现权利要求 1 至 16 中任一项所述方法的步骤。

说明书

技术领域

本申请涉及人工智能推理服务、混合专家模型、分布式并行计算、上下文并行、数据并行负载均衡和键值缓存管理技术领域，特别是涉及一种大模型推理中缓解 MoE 气泡的全量上下文并行调度方法、装置、电子设备和计算机可读介质。

背景技术

大模型推理通常采用自回归生成方式。对于长文档理解、代码仓库分析、知识库问答和智能体任务规划等场景，单个请求可能包含数万至数十万 token 的上下文，甚至达到百万 token。随着上下文长度增长，推理服务不仅面临更高的首字时延，还会在解码阶段持续访问不断增长的键值缓存 (KV Cache)。

在解码阶段，每生成一个 token，注意力计算需要访问历史 token 对应的键值缓存。对于一个具有 n_layers 层、每层 n_kv_heads 个键值头、每个键值头维度为 d_head 、以 B_dtype 字节存储的模型，当上下文长度达到 L 时，单个请求的键值缓存总字节数（即请求级键值缓存足迹 F ）可表示为：

$$F = 2 \times n_layers \times L \times n_kv_heads \times d_head \times B_dtype$$

当 L 较大时，键值缓存读取量成为逐词时延（Time Per Output Token, TPOT）和尾延迟的重要来源。在数据并行（Data Parallelism, DP）推理服务中，不同请求通常被分配到不同计算副本执行。如果少量长上下文请求集中在某些数据并行副本上，这些副本在注意力阶段需要遍历更大的键值缓存，导致到达后续 MoE 层的时间显著晚于其他副本。

混合专家模型（Mixture of Experts, MoE）在每个 MoE 层中通常包括路由、专家间通信和专家前馈计算。在包含专家并行或跨副本专家通信的部署中，同一同步组内的多个计算副本需要在 MoE 层附近进行对齐或集合通信。当某一数据并行副本因长上下文注意力或键值缓存访存压力成为 straggler 时，其他较快副本会在 MoE 同步点等待，形成 MoE bubble。该等待会放大到后续解码步，降低有效吞吐并恶化尾延迟。

现有请求级数据并行调度通常依据请求数量、队列长度或键值缓存使用量选择目标副本，可以在一定程度上缓解缓存容量不均衡，但无法直接消除同一 MoE 同步组中各副本到达 MoE 层的时间差。另一方面，上下文并行（Context Parallelism, CP）能够沿序列维度切分键值缓存和注意力计算，使单个长请求由多个副本协同执行，从而降低单副本注意力阶段耗时。对于本申请关注的问题，调度器在数据并行路径和预设计算域内全量上下文并行路径之间做选择：当某请求若单副本执行会加重 MoE 同步等待时，使用全量 CP 将其注意力访存和计算分摊到整个计算域，使各副本更接近同步地进入 MoE 层；当请求不会导致明显 MoE bubble 时，仍走普通 DP 路径以避免不必要通信。

因此，需要一种面向 MoE 推理服务的调度方法，能够感知 DP 副本间负载不均衡、注意力阶段预计完成时间和专家路由偏斜，在 DP 路径与全量 CP 路径之间选择执行方式，从而缓解 MoE bubble。

发明内容

本申请提供了一种大模型推理中缓解 MoE 气泡的全量上下文并行调度方法、装置、电子设备和计算机可读介质，用以解决数据并行副本间负载不均衡导致的 MoE 同步等待气泡、长上下文请求造成的注意力阶段 straggler、专家输入负载偏斜放大尾延迟以及全量上下文并行执行中的跨副本缓存映射和结果聚合问题。

本申请提供了如下方案：

根据第一方面，提供了一种大模型推理中缓解 MoE 气泡的全量上下文并行调度方法。该方法包括：接收推理请求并获得上下文长度、键值缓存需求量、服务等级目标和 MoE 层路由相关统计；获得多个数据并行计算副本的键值缓存使用量、待处理请求数、注意力阶段

预计完成时间、MoE 层同步等待时间、专家输入负载偏斜和跨副本通信状态；估计推理请求在数据并行路径下的第一气泡代价，以及在预设计算域内全量上下文并行路径下的第二气泡代价和通信代价；当第二气泡代价低于第一气泡代价且通信代价满足预设约束时，将请求绑定至预设计算域内全部参与副本并以全量上下文并行路径执行；否则，将请求调度至单个目标计算副本并以数据并行路径执行。

根据第二方面，提供了一种大模型推理中缓解 MoE 气泡的全量上下文并行调度装置。该装置包括请求分析模块、状态采集模块、气泡代价估计模块、路径选择模块、缓存分片管理模块、注意力执行模块和 MoE 对齐模块。

根据第三方面，提供了一种电子设备，包括一个或多个处理器以及与所述一个或多个处理器关联的存储器，所述存储器用于存储程序指令，所述程序指令在被所述一个或多个处理器读取执行时，执行上述第一方面中任一项所述的方法的步骤。

根据第四方面，提供了一种计算机可读介质，其上存储有计算机程序，该程序被处理器执行时实现上述第一方面中任一项所述的方法的步骤。

根据第五方面，提供了一种计算机程序产品，包括计算机程序，该计算机程序被处理器执行时实现上述第一方面中任一项所述方法的步骤。

附图说明

为了更清楚地说明本申请实施例或现有技术中的技术方案，下面将对实施例中所需要使用的附图作简单介绍。显而易见地，下面描述中的附图仅仅是本申请的一些实施例，对于本领域普通技术人员来讲，在不付出创造性劳动的前提下，还可以根据这些附图获得其他附图。

图 1 为本申请实施例提供的数据并行副本负载不均衡导致 MoE 气泡的示意图。

图 2 为本申请实施例提供的 MoE 气泡感知的 DP / 全量 CP 执行架构示意图。

图 3 为本申请实施例提供的键值缓存布局映射与重排示意图。

图 4 为本申请实施例提供的全量上下文并行场景下键值缓存布局与映射关系示意图。




图 1：数据并行副本负载不均衡导致 MoE 气泡示意图




图 2: MoE 气泡感知的 DP / 全量 CP 执行架构示意图

PD 分离中的 KV Cache 布局映射与转换

源端按 TP/PP 与 KV head 生成缓存，连接器按映射关系传输和重排，目标端按 PageAttention 槽位消费分片 KV





图 3：键值缓存布局映射与重排示意图



路由元数据包括 req_id、domain_id、D_full、virtual_block_id、replica_id、slot_id 和 block 状态。该映射使全量 CP 能接入分页注意力、连续批处理和 MoE 层调度。

图 4：全量上下文并行场景下键值缓存布局与映射关系示意图

具体实施方式

下面将结合本申请实施例中的附图，对本申请实施例中的技术方案进行清楚、完整地描述。显然，所描述的实施例仅仅是本申请一部分实施例，而不是全部的实施例。基于本申请中的实施例，本领域普通技术人员所获得的所有其他实施例，都属于本申请保护的范围。

本申请中的计算副本可以是数据并行副本、推理实例、计算设备组、加速设备组或其他能够独立执行大模型部分或全部推理计算的执行单元。计算设备可以包括 GPU、NPU、AI 加速器、通用处理器或其组合。本申请的核心方案不依赖特定硬件平台。

本申请中的数据并行路径是指将一个推理请求绑定至单个目标计算副本执行注意力计算和后续 MoE 计算的路径。本申请中的全量上下文并行路径是指将一个推理请求绑定至预设计算域内全部参与副本，沿序列维度分片执行注意力计算并聚合结果的路径。预设计算域由部署配置确定。

图 1 示出了数据并行副本负载不均衡导致 MoE 气泡的情形。长上下文请求所在副本在注意力阶段耗时更长，较快副本提前到达 MoE 层后等待较慢副本，形成同步等待区间。该等待区间即为 MoE bubble。

图 2 示出了 MoE 气泡感知的 DP / 全量 CP 执行架构。系统包括请求队列、MoE bubble 感知调度器、运行状态视图、DP 执行路径、全量 CP 执行路径、跨副本缓存管理器和注意力后端。调度器根据 DP 副本间负载不均衡和 MoE bubble 估计结果选择执行路径。

下面结合步骤 101 至步骤 113 对本申请方法的具体执行流程进行详细描述。

步骤 101，接收推理请求，获得请求特征。

系统接收大模型的推理请求，提取请求特征。请求特征可以包括 prompt 长度 P 、已生成 token 数 G 、当前上下文长度 $L = P + G$ 、最大生成长度 M 、服务等级目标、请求优先级、是否命中前缀缓存、预计新增键值缓存块数以及 MoE 层路由相关统计。

MoE 层路由相关统计可以来自历史解码步、模型路由器预测、同类请求统计或在线采样，包括各 MoE 层专家命中计数、top-k 路由分布、专家容量因子、专家输入 token 数的方差、最大专家输入 token 数与平均专家输入 token 数的比值等。

步骤 102，采集 DP 副本运行状态。

系统采集各数据并行计算副本的实时运行状态。运行状态可以包括：各计算副本 i 的已占用键值缓存块数 U_i 或字节数、剩余键值缓存容量 C_i 、待处理请求数 Q_i 、当前解码批大小、注意力阶段预计完成时间 A_i 、历史或当前 MoE 层同步等待时间 B_i 、专家输入负载偏斜 E_i 、跨副本通信链路带宽及其利用率、通信队列深度、近若干步逐词时延的滑动平均值和滑动尾部百分位值。

步骤 103，计算请求级键值缓存足迹和注意力阶段耗时。

请求级键值缓存足迹 F 表征该请求对缓存容量和缓存访存带宽的占用规模。在一种实施例中，足迹 F 可以通过下式估计：

$$F = 2 \times n_layers \times L \times n_kv_heads \times d_head \times B_dtype$$

系统可以根据 F 、有效高带宽存储器带宽 B_hbm 、已有批次中其他请求的键值缓存足迹以及注意力后端性能模型，估计该请求在单个数据并行副本上执行注意力阶段的耗时 T_attn_dp 。该耗时用于估计目标副本到达 MoE 同步点的时间。

步骤 104，估计数据并行路径下的第一气泡代价。

对于每个候选目标计算副本 i ，系统估计若将该请求以数据并行路径调度至副本 i ，则副本 i 到达下一 MoE 同步点的预计时间：

$$T_i^{DP} = A_i + T_attn_dp + T_queue_i$$

其中， A_i 表示副本 i 当前批次注意力阶段预计完成时间， T_queue_i 表示该请求在副本 i 上的排队等待时间。设同一 MoE 同步组内其他副本到达 MoE 同步点的预计时间为 T_j ，则数据并行路径下的第一气泡代价可以表示为：

$$B_DP(i) = \sum_j \max(0, T_i^{DP} - T_j) + \lambda \times E_DP(i)$$

其中， $E_DP(i)$ 表示将该请求放入副本 i 后预计形成的专家输入负载偏斜， λ 为权重系数。第一项刻画副本 i 过慢导致其他副本等待的时间，第二项刻画 MoE 专家路由不平衡引发的额外等待或容量冲突。

步骤 105，估计全量上下文并行路径下的第二气泡代价和通信代价。

预设计算域包括全部参与副本集合 D_full 。系统估计若将该请求以全量上下文并行路径执行，则该请求的键值缓存和注意力计算沿序列维度被分摊到 D_full 中的全部参与副本。此时每个参与副本需要读取约 $F / |D_full|$ 的键值缓存分片，并承担分片注意力计算、统计量归约和输出聚合开销。

全量上下文并行路径下的注意力阶段预计完成时间可表示为：

$$T^{FullCP} = \max_r(T_attn_r) + T_reduce + T_meta$$

其中， T_attn_r 为第 r 个参与副本上的分片注意力耗时， T_reduce 为局部指数归一化统计量和输出聚合的通信耗时， T_meta 为路由元数据和缓存映射处理耗时。第二气泡代价可以表示为：

$$B_FullCP = \sum_j \max(0, T^{FullCP} - T_j) + \mu \times E_FullCP$$

其中， E_FullCP 为全量上下文并行路径下的专家输入负载偏斜， μ 为权重系数。通信代价 C_FullCP 可以根据统计量归约、输出聚合、跨副本缓存访问以及通信链路利用率估计。

步骤 106，选择 DP 路径或全量 CP 路径。

系统根据第一气泡代价、第二气泡代价和通信代价选择执行路径。在一种实施例中，满足下式时选择全量上下文并行路径：

$$B_DP(best) - B_FullCP > C_FullCP + \delta$$

其中, $B_DP(best)$ 为各目标计算副本中最小的数据并行气泡代价, δ 为防抖裕量。若上述条件不满足, 或者通信链路拥塞、参与副本不可用、全量 CP 路径预计违反服务等目标, 则选择数据并行路径。

该决策在两条路径之间选择: DP 路径和预设计算域内全量 CP 路径。预设计算域的规模由部署配置确定, 例如一个节点内的全部 DP attention 副本或一个通信域内的全部 DP attention 副本。

为便于理解上述决策逻辑, 下面给出一个简化的量化示例。设 MoE 同步组包含 8 个数据并行副本。某长上下文请求 R 的上下文长度 $L = 128K$, 请求级键值缓存足迹约 16 GB。当前各副本的注意力阶段预计完成时间分别为: 副本 0 约 30 ms (轻载), 副本 1 约 28 ms, ..., 副本 7 约 32 ms。各副本到达 MoE 同步点的时间 spread 约 4 ms。

若选择 DP 路径, 将请求 R 调度至轻载副本 0: 副本 0 需要完成 R 的注意力计算, 由于 16 GB 键值缓存遍历, 单副本注意力耗时约 120 ms; 副本 0 的预计 MoE 到达时间变为 $30 + 120 = 150$ ms, 其余副本约 28–32 ms。此时 spread 扩大为 $150 - 28 = 122$ ms, 其余 7 个副本在 MoE 同步点等待约 118–122 ms, 构成显著的 MoE bubble。

若选择全量 CP 路径, 请求 R 的键值缓存分片至全部 8 个副本: 每副本仅需读取约 2 GB 的分片, 分片注意力耗时约 18 ms, LSE 归约和输出聚合通信耗时约 5 ms。全部 8 个副本的注意力阶段同时结束, MoE 到达时间均为约 $30 + 18 + 5 = 53$ ms (各副本之间差异归零)。此时 spread = 0, MoE bubble 消除。通信代价 5 ms 远小于 bubble 降低量 $122 - 0 = 122$ ms, 全量 CP 路径被选择。

步骤 107, 数据并行路径执行。

当选择数据并行路径时, 系统将请求调度至综合负载评分最低且剩余缓存容量满足请求需求的目标计算副本执行。综合负载评分可以根据键值缓存使用量 U_i 、待处理请求数 Q_i 、预计注意力完成时间 A_i 、历史 MoE 同步等待时间 B_i 和专家输入负载偏斜 E_i 确定。

数据并行路径不引入跨副本注意力聚合通信, 适合上下文较短、不会扩大 MoE bubble 或通信链路繁忙的请求。

步骤 108, 全量 CP 路径绑定全部参与副本。

当选择全量上下文并行路径时, 系统将请求绑定至预设计算域 D_full 中的全部参与副本, 形成该请求的键值缓存绑定集合。绑定集合中的每个参与副本承担该请求在序列维度上的一部分键值缓存和分片注意力计算。

步骤 109, 键值缓存分片。

系统将键值缓存沿序列维度分片至全部参与副本。分片方式可以为以下至少一种: 连续分片、块轮转分片或交错分片。图 4 示出了全量上下文并行场景下键值缓存布局与映射关系。

步骤 110，维护跨副本缓存映射和虚拟块索引。

跨副本缓存管理器维护二维槽位映射表。该表的第一维对应参与副本标识，第二维对应序列位置或缓存块编号。表项记录物理槽位编号、块状态、引用计数、所属请求标识、数据类型以及数据可读状态。跨副本缓存管理器基于二维槽位映射表生成虚拟块索引，使注意力后端通过逻辑连续的虚拟块访问分布在全部参与副本上的键值缓存。

步骤 111，注入路由元数据。

系统为全量 CP 路径请求生成路由元数据。路由元数据包括：请求标识 req_id、预设计算域标识 domain_id、全部参与副本集合 D_full、跨副本缓存映射表 M 以及结果聚合路径。该路由元数据被注入批次执行描述符或计算图，用于驱动注意力后端读取本地缓存分片、参与跨副本通信并返回聚合结果。

步骤 112，执行分片注意力计算并聚合结果。

在全量 CP 路径下，请求由全部参与副本协同完成分片注意力计算。为保证聚合后的注意力输出与未分片计算在数学上等价，采用基于局部指数归一化统计量的精确聚合方式。

具体而言，设当前解码步的查询向量为 q ，全局键值缓存为 K, V ，全部参与副本集合为 D_{full} 。系统将序列维度切分为多个分片，第 r 个参与副本持有位置集合 I_r 上的 K_r, V_r 。第 r 个参与副本先基于本地键值缓存分片计算本地注意力分数：

$$s_{r,j} = q \cdot k_j^T, \quad j \in I_r$$

在该参与副本内部，按照本地分片上的 softmax 计算本地输出 O_r ：

$$Z_r = \sum_{j \in I_r} \exp(s_{r,j})$$

$$O_r = (\sum_{j \in I_r} \exp(s_{r,j}) \cdot v_j) / Z_r$$

其中， Z_r 为第 r 个参与副本上本地注意力分数的指数和。为了便于跨副本聚合，参与副本还计算本地指数归一化统计量：

$$LSE_r = \log(Z_r) = \log(\sum_{j \in I_r} \exp(s_{r,j}))$$

各参与副本通过 all-gather、all-reduce 或点对点通信交换各自的 LSE_r 。为提高数值稳定性，先确定所有参与副本中的最大统计量：

$$LSE_{max} = \max_r(LSE_r)$$

然后按照下式将每个本地输出 O_r 转换为全局 softmax 下的加权贡献：

$$w_r = \exp(LSE_r - LSE_{max})$$

$$= (\sum_{j \in I_r} \exp(s_{r,j})) / \exp(LSE_{max})$$

最后，按照参与副本权重对本地输出进行归一化加权求和，得到全局注意力输出：

$$O = (\sum_r w_r \cdot O_r) / (\sum_r w_r)$$

上述公式等价于直接在完整序列上计算 $O = \text{softmax}(qK^T)V$ 。上述聚合过程保持了精确注意力计算，不依赖稀疏化或近似剪枝。

在一种实施例中， w_r 和 $w_r \cdot O_r$ 的归约通过一次 all-reduce 完成，聚合完成后全部参与副本持有相同的全局注意力输出 O 。对于采用专家并行 (Expert Parallelism, EP) 的 MoE 模型，各参与副本随即携带 O 进入 MoE 层的 all-to-all 路由分发，将当前解码 token 发送至对应专家所在的副本执行专家前馈计算。由于全量 CP 路径使全部参与副本的注意力阶段同步完成，各副本几乎同时发起 MoE all-to-all，从而消除因注意力 straggler 导致其他副本在 all-to-all 入口等待的 bubble。对于 MoE 层采用全复制模式的部署 (非 EP)，可仅由主副本携带 O 继续执行 MoE 层以避免冗余计算，其余参与副本仅参与注意力阶段的分片和同步。

步骤 113，MoE 层对齐和状态更新。

全量 CP 路径完成分片注意力聚合后，全部参与副本在同一 MoE 同步组内进入专家路由、跨专家通信或专家前馈计算。由于长上下文请求的注意力耗时经分片后与各副本上其他短请求的注意力耗时趋于一致，到达 MoE 同步点的最大时间差 (spread) 被压缩——不再出现某一副本远慢于其他副本的 straggler 效应——从而降低同步等待时间。

输出 token 生成后，系统更新请求上下文长度、新增键值缓存块映射、各参与副本的键值缓存使用量、MoE 同步等待统计和专家输入负载偏斜统计。系统可以利用连续多个解码步中的统计更新气泡代价估计参数，以提升后续路径选择的准确性。

在一种可选实施例中，本申请可以与预填充-解码分离 (Prefill-Decode Disaggregation, PD 分离) 架构配合。图 3 示出了 PD 分离场景下的键值缓存布局映射与重排方式。当预填充侧和解码侧的并行配置不同，或者模型采用不同注意力结构 (MHA、GQA、MQA 或 MLA) 时，系统根据键值头编号、层编号、源端张量并行标识、目标端张量并行标识、源端流水并行阶段和目标端流水并行阶段之间的映射关系确定键值缓存的读取和写入位置。该布局映射机制确保 PD 分离下全量 CP 路径的键值缓存跨节点传输和重排的正确性。

表 1 示出了本申请实施例中路径选择所使用的部分输入信号及其含义和用途。

输入信号	含义	用途
上下文长度 L	prompt token 与已生成 token 的总长度	估计键值缓存足迹和注意力耗时
请求级键值缓存足迹 F	单请求所需缓存容量和访存规模，可由 L 计算或实测	估计 DP 路径 straggler 风险和全量 CP 收益
键值缓存使用量 U_i	各副本已占用缓存块或字节数	选择 DP 目标副本，估计副本压力

待处理请求数 Q_i	各副本等待或正在执行的请求数量	估计排队时间和注意力完成时间
MoE 同步等待 B_i	副本在 MoE 层附近等待其他副本的时间	估计 MoE bubble
专家输入偏斜 E_i	各专家输入 token 数的不均衡程度	估计专家负载不均衡引发的尾延迟
通信状态	互联带宽利用率、队列深度和拥塞状态	约束全量 CP 路径的统计量归约和输出聚合

表 2 示出了一个非限制性的路径选择示例。

场景	执行路径	说明
短上下文且 MoE 等待较低	DP 路径	单副本执行不会扩大 MoE bubble
长上下文集中到某个 DP 副本	全量 CP 路径	分摊注意力访存，降低 straggler 对 MoE 同步点的拖尾
专家输入偏斜显著且通信空闲	全量 CP 路径	通过全域协同执行降低局部副本过慢导致的等待
通信链路拥塞	DP 路径	避免全量 CP 归约和聚合通信进一步放大拥塞
全量 CP 预计不降低气泡代价	DP 路径	保持低通信开销

有益效果

由上述实施例可以看出，本申请围绕 MoE bubble 感知，在数据并行路径和预设全量上下文并行路径之间选择，具有以下有益效果。

第一，缓解 DP 副本负载不均衡导致的 MoE bubble。本申请将注意力阶段预计完成时间、MoE 同步等待时间和专家输入偏斜纳入调度决策，能够识别会拖慢 MoE 同步组的长上下文请求，并通过全量 CP 路径分摊其注意力访存和计算压力，减少其他副本在 MoE 层附近的等待。

第二，聚焦 MoE bubble 缓解和 DP 负载均衡。本申请的运行时决策围绕 DP 副本间负载不均衡、注意力阶段 straggler 和 MoE 同步等待展开，使全量 CP 路径成为缓解 MoE

bubble 的执行手段，而非独立的并行配置目标。

第三，跨副本缓存映射和虚拟块索引屏蔽分布复杂度。本申请通过二维槽位映射表记录每个 token 的键值缓存在哪个参与副本的哪个物理槽位上，并通过虚拟块索引将物理分布抽象为逻辑连续视图。上层注意力后端仅通过虚拟块索引即可定位跨副本键值数据。

第四，精确注意力聚合，不依赖近似或稀疏化。本申请采用基于局部指数归一化统计量的精确聚合方式，使分片注意力输出与全序列单副本注意力输出在数学上等价。该方式不需要模型重训练或精度补偿，适合在线推理服务。

第五，与 PD 分离和多种注意力结构兼容。本申请通过键值缓存布局映射关系覆盖预填充侧和解码侧并行配置不同的情况，适用于 MHA、GQA、MQA 或 MLA 等注意力结构。

第六，跨模型和跨硬件的普适性。本申请依赖标准的集合通信、点对点通信或远程直接内存访问，以及通用的键值缓存分片和注意力聚合机制，不要求特定硬件平台或专有通信库。

替代方案

基于上述核心实施例，本领域技术人员可以理解，其技术构思允许有多种替代技术方案，这些方案均应落入本申请的保护范围，其包括但不限于以下替代技术方案。

替代方案一：不同的 MoE bubble 估计方式。本申请优选实施方式中使用注意力阶段预计完成时间、MoE 同步等待时间和专家输入偏斜估计气泡代价。替代方案可以采用滑动窗口统计、离线标定模型、排队论模型、机器学习回归模型或强化学习策略估计气泡代价。

替代方案二：不同的全量计算域定义方式。预设计算域可以是同一节点内全部数据并行副本、同一通信域内全部数据并行副本、同一机架内带宽满足预设条件的副本集合，或者由部署配置静态指定的其他副本集合。该替代方案不改变运行时只在 DP 路径和全量 CP 路径之间选择的核心构思。

替代方案三：不同的键值缓存分片方式。本申请支持连续分片、块轮转分片和交错分片。替代方案可在分片粒度上进行调整，或者根据各参与副本的剩余缓存容量进行非均匀分片，以适配容量异构的计算副本。

替代方案四：不同的注意力聚合方式。本申请优选实施方式中采用基于局部指数归一化统计量的精确注意力聚合方式。替代方案可在对精度要求不极端的场景下采用近似聚合方式，以进一步降低聚合通信开销。

替代方案五：不同的通信原语与重叠策略。本申请涉及的跨副本通信可采用 all-reduce、reduce-scatter、all-gather 或点对点通信的不同组合实现，具体通信原语的选择可根据集群互联拓扑和通信库性能特征进行优化。此外，可将通信操作与本地注意力分数计算、MoE 路由或专家前馈计算进行流水线重叠。

这些变型均体现了”感知 DP 副本间负载不均衡和 MoE 同步等待，在数据并行路径与预设计算域内全量上下文并行路径之间选择，并通过跨副本缓存映射、虚拟块索引和精确

注意力聚合管理全量 CP 执行”的核心发明构思。

装置实施例

根据另一方面的实施例，提供了一种大模型推理中缓解 MoE 气泡的全量上下文并行调度装置。该装置包括请求分析模块、状态采集模块、气泡代价估计模块、路径选择模块、缓存分片管理模块、注意力执行模块和 MoE 对齐模块。各模块可以通过软件、硬件或软硬件结合的方式实现。

请求分析模块被配置为接收大模型的推理请求，获得所述推理请求的上下文长度、键值缓存需求量、服务等级目标以及 MoE 层路由相关统计。状态采集模块被配置为周期性或事件驱动地采集推理系统中多个数据并行计算副本的键值缓存使用量、待处理请求数、注意力阶段预计完成时间、MoE 层同步等待时间、专家输入负载偏斜和跨副本通信状态。气泡代价估计模块被配置为估计所述推理请求在数据并行路径下的第一气泡代价，以及在预设计算域内全量上下文并行路径下的第二气泡代价和通信代价。路径选择模块被配置为在所述第二气泡代价低于所述第一气泡代价且所述通信代价满足预设约束时选择全量上下文并行路径，否则选择数据并行路径。缓存分片管理模块被配置为实现二维槽位映射表、虚拟块索引以及键值缓存的跨副本分片与生命周期管理。注意力执行模块被配置为执行分片注意力计算并完成局部指数归一化统计量归约和输出聚合。MoE 对齐模块被配置为根据注意力阶段完成时间和 MoE 同步等待时间调度所述推理请求进入 MoE 层。

作为一种可实现的方式，所述装置还包括参数更新模块，被配置为根据连续多个解码步中的 MoE 同步等待时间和专家输入负载偏斜更新气泡代价估计参数。

作为一种可实现的方式，所述装置还包括重叠调度模块，被配置为将跨副本通信操作与注意力后端的本地注意力分数计算、MoE 路由或专家前馈计算进行流水线编排，以计算时间覆盖至少部分通信延迟。

本说明书中的各个实施例均采用递进的方式描述，各个实施例之间相同相似的部分互相参见即可。以上所描述的装置实施例仅仅是示意性的，其中所述作为分离部件说明的单元可以是或者也可以不是物理上分开的；可以根据实际的需要选择其中的部分或者全部模块来实现本实施例方案的目的。本领域普通技术人员在不付出创造性劳动的情况下，即可以理解并实施。

电子设备与计算机可读介质

本申请实施例还提供了一种电子设备，包括：一个或多个处理器；以及与所述一个或多个处理器关联的存储器，所述存储器用于存储程序指令，所述程序指令在被所述一个或多个处理器读取执行时，执行前述方法实施例中任一项所述的方法的步骤。其中，所述处理器可以采用通用处理器、神经网络处理器、图形处理器或者一个或多个集成电路等方式实现，用于执行相关程序，以实现本申请所提供的技术方案；多个计算设备之间可通过片

间高速互联或节点间网络互联，以执行本申请所述的统计量归约、键值缓存跨副本传输、结果聚合和 MoE 层通信等操作。

此外，本申请实施例还提供了一种计算机可读存储介质，其上存储有计算机程序，该程序被处理器执行时实现前述方法实施例中任一项所述的方法的步骤。本申请还提供了一种计算机程序产品，包括计算机程序，该计算机程序在被处理器执行时实现前述方法实施例中任一项所述的方法的步骤。

通过以上的实施方式的描述可知，本领域的技术人员可以清楚地了解到本申请可借助软件加必需的通用硬件平台的方式来实现。本申请可以应用于 GPU、NPU、AI 加速器、通用处理器或其组合构成的推理系统，也可以应用于单机多卡、跨节点集群或云端推理服务。本申请所述通信方式可以采用集合通信、点对点通信、远程直接内存访问或其他跨副本数据传输方式，具体实现不构成对保护范围的限制。

以上对本申请所提供的技术方案进行了详细介绍，本文中应用了具体实施例对本申请的原理及实施方式进行了阐述，以上实施例的说明只是用于帮助理解本申请的方法及其核心思想；同时，对于本领域的一般技术人员，依据本申请的思想，在具体实施方式及应用范围上均会有改变之处。综上所述，本说明书内容不应理解为对本申请的限制。